

Advanced Data Modelling

Maulana Hafidz Ismail

11 Nov 2025

Contents

1 Data Modeling and Management

1.1 Pengenalan Pemodelan Data

Data Model adalah representasi visual dari elemen data yang berbeda dan bagaimana mereka saling berhubungan.

1.2 Tingkatan Model Database

- Conceptual Data Model: Model yang menggambarkan struktur data secara umum tanpa detail teknis.
- Logical Data Model: Model yang lebih terperinci yang menunjukkan bagaimana data akan disimpan dalam database.
- Physical Data Model: Model yang menggambarkan bagaimana data akan disimpan secara fisik dalam sistem.

1.3 Normalisasi Database

Normalization adalah proses untuk mengatur data dalam database untuk mengurangi redundansi dan menghindari anomali.

- Insertion Anomaly: Kesulitan dalam menambahkan data baru karena ketergantungan pada data lain.
- Update Anomaly: Masalah yang muncul saat memperbarui data yang terduplikasi.
- Deletion Anomaly: Kehilangan data penting saat menghapus data yang tidak relevan.

1.4 MySQL Workbench

- MySQL Workbench: Alat visual untuk pemodelan dan manajemen database.
- Forward Engineering: Proses mengubah model data menjadi skema database di MySQL.
- Reverse Engineering: Proses membuat model data dari database yang sudah ada.

1.5 Data Warehousing

- Data Warehouse: Repositori data terpusat yang mengintegrasikan dan menyimpan data dari berbagai sumber.
- ETL (Extract, Transform, Load): Proses untuk mengambil data dari sumber, mengubahnya, dan memuatnya ke dalam data warehouse.

- Data Marts: Subset dari data warehouse yang berfokus pada area bisnis tertentu.

1.6 Pemodelan Data Dimensional

- Dimensional Data Modeling: Teknik pemodelan yang menggunakan dimensi dan fakta, biasanya dalam bentuk skema bintang (star schema) atau skema salju (snowflake schema).
- Grain: Tingkat detail yang ditentukan dalam model data.

1.7 Analisis Data

Data Analytics adalah proses menganalisis data untuk mendapatkan wawasan.

- Quantitative Data: Data yang dapat diukur dan dinyatakan dalam angka.
- Qualitative Data: Data yang bersifat deskriptif dan tidak dapat diukur dengan angka.

1.8 Alat Analisis Data

Tableau adalah alat untuk visualisasi data yang memungkinkan pengguna untuk membuat dashboard interaktif dan menganalisis data secara mendalam.

1.9 Pemodelan Data

- Pemodelan data memberikan representasi visual dari elemen data dan menunjukkan bagaimana mereka saling berhubungan. Ini membantu memahami bagaimana data disimpan, diakses, diperbarui, dan ditanyakan dalam basis data.
- Pemodelan data digunakan untuk mengembangkan berbagai jenis basis data, terutama entity relational databases, yang direncanakan dengan menggunakan **entity relationship diagram (ERD)**.

1.10 Tingkat Pemodelan Data

- Conceptual Data Model: Model ini memberikan gambaran umum yang tinggi tentang elemen data yang disebut entities. Tujuannya adalah untuk menunjukkan hubungan antara entitas dalam basis data. Contoh entitas untuk **M&G** adalah pelanggan, produk, dan pesanan.
- Logical Data Model: Model ini lebih rinci dan mencakup atribut dari setiap entitas, mendefinisikan primary keys, dan spesifikasi foreign keys. Misalnya, client ID adalah primary key untuk tabel klien, dan menghubungkan tabel klien dengan tabel pesanan melalui foreign key client ID.

- **Physical Data Model:** Model ini digunakan untuk membuat skema SQL internal dari basis data. Ini mencakup fitur seperti datatypes, constraints, dan atribut. Contohnya, mendefinisikan datatype seperti varchar untuk atribut nama lengkap dan integer untuk nomor kontak. Constraints seperti NOT NULL juga diterapkan untuk memastikan setiap kolom berisi data.

1.11 Tipe-tipe Data Model

Model data memberikan representasi visual dari elemen-elemen data dan menggambarkan bagaimana mereka saling berhubungan. Model ini memberikan pemahaman kepada insinyur basis data tentang cara data disimpan, diakses, diperbarui, dan diinterogasi dalam basis data.

Terdapat beberapa jenis model data yang dapat digunakan untuk merancang sistem basis data. Pilihan model yang digunakan sebaiknya didasarkan pada kesesuaiannya dalam mendukung kebutuhan bisnis.

1.11.1 Model Data Relasional

Model ini merepresentasikan basis data sebagai kumpulan relasi, di mana setiap relasi disajikan dalam bentuk tabel yang menyimpan informasi dalam baris dan kolom.

Keuntungan: Lebih sederhana digunakan dibandingkan model lain, memudahkan identifikasi dan akses data.

1.11.2 Model Entity Relationship

Model ini mirip dengan model relasional, tetapi setiap tabel dipresentasikan sebagai entitas terpisah dengan atributnya sendiri.

Model hubungan entitas biasanya digambarkan dalam diagram ER yang menampilkan entitas-entitas dalam basis data dan hubungan-hubungan yang berbeda di antara mereka, di mana setiap entitas memiliki kumpulan atribut yang terkait.

Model ini juga menggambarkan berbagai jenis multiplisitas, termasuk satu-ke-satu, satu-ke-banyak, dan banyak-ke-banyak.

Diagram ER berikut ini menggambarkan sistem pemesanan janji operasi. Sistem ini terdiri dari empat entitas: Dokter, Operasi, Janji, dan Pasien.

Setiap entitas memiliki kumpulan atribut, dan semua entitas terhubung melalui kunci asing. Menurut diagram ini:

- Seorang pasien dapat membuat satu atau beberapa janji temu.
- Beberapa janji temu dapat ditugaskan kepada setiap dokter.
- Beberapa janji temu berlangsung di sebuah klinik tertentu.

Model data hubungan entitas mendukung persyaratan data operasi, dan diagram ER menampilkan struktur database secara mudah digunakan, sehingga

Anda dapat menggunakannya untuk mendokumentasikan database Anda dan berkomunikasi tentang strukturnya dengan pemangku kepentingan Anda.

Anda juga dapat membuat diagram ini dalam alat pengembangan terintegrasi seperti MySQL Workbench dan mengimplementasikan model database secara langsung di MySQL.




Figure 1:

1.11.3 Model Data Hierarkis

Model ini mengorganisir data dalam struktur pohon (tree-like) dengan hubungan parent-child.

Hanya dapat merekam hubungan one-to-many, di mana setiap child node hanya dapat memiliki satu parent node.

Model data berikut ini menggambarkan struktur database perusahaan asuransi. Dalam diagram ini, perusahaan asuransi disusun sebagai berikut:

- Departemen adalah node akar,
- Node Agen dan Staf terhubung ke node akar Departemen.
- Dan node Komputer dan Ketenagakerjaan terhubung ke node akar Staf.




Figure 2:

Anda mungkin telah memperhatikan bahwa salah satu keunggulan utama model ini adalah kesederhanaan strukturnya. Selain itu, karena setiap catatan hanya memiliki satu induk, Anda dapat menavigasi basis data dengan cepat dan efisien. Namun, Anda perlu menyadari bahwa dalam model ini, jika Anda menghapus node induk, maka catatan anak yang terkait juga akan dihapus.

Selain itu, model ini tidak mendukung hubungan banyak-ke-banyak, yang mungkin diperlukan dalam beberapa kasus (seperti dalam skenario operasi sebelumnya).

Sulit juga untuk merestrukturisasi struktur basis data untuk mengakomodasi persyaratan baru. Melakukannya dapat mengganggu hubungan orang tua-anak yang sudah ada.

Anda dapat menggunakan diagram ER untuk mewakili tingkat detail yang lebih tinggi dari model ini seperti yang ditunjukkan di bawah ini.




Figure 3:

1.11.4 Model Object Oriented

Model ini berdasarkan konsep berorientasi objek (Object Oriented), di mana setiap objek diterjemahkan menjadi kelas yang mendefinisikan karakteristik dan perilakunya.

Dalam model ini, Anda dapat menggunakan berbagai jenis hubungan antara objek, seperti agregasi, komposisi, dan pewarisan. Fitur-fitur ini membuat basis data berorientasi objek cocok untuk proyek yang kompleks. Namun, penggunaan model ini memerlukan pemahaman yang baik tentang pemrograman berorientasi objek.

Dalam diagram pendaftaran kursus berikut, terdapat enam kelas:

- Person,
- Student,
- Professor,
- Course,
- Address
- dan Enrolment.

Setiap kelas terdiri dari sekumpulan atribut dan metode.




Figure 4:

Dalam contoh ini, setiap kelas mewakili objek-objek serupa dalam basis data. Artinya, objek-objek serupa memiliki karakteristik dan perilaku yang sama. Misalnya, setiap mahasiswa yang terdaftar dalam sistem basis data memiliki kumpulan atribut (atau variabel instance) yang sama, seperti ID dan jenis. Selain itu, setiap instance objek dari suatu kelas menggunakan operasi yang sama yang dinyatakan dalam kelas tersebut.

Selain itu, terdapat berbagai jenis hubungan yang didefinisikan dalam diagram sebagai berikut:

- Setiap siswa dan dosen adalah orang (hubungan pewarisan) dan setiap orang terkait dengan alamat.
- Setiap siswa dan dosen adalah subtype dari orang, dan setiap orang berfungsi sebagai supertipe untuk setiap siswa dan dosen.
- Setiap pendaftaran melibatkan siswa dan mata kuliah. Kelas pendaftaran dalam hal ini disebut kelas asosiasi.
- Setiap dosen ditugaskan ke mata kuliah.

1.11.5 Model Data Dimensional

Model ini didasarkan pada dua konsep kunci, yaitu fakta (facts) dan dimensi (dimensions). Fakta adalah pengukuran yang diperoleh dari suatu proses, sedangkan dimensi mendefinisikan konteks pengukuran tersebut.

Keuntungan: Mengoptimalkan basis data untuk pengambilan data yang lebih cepat dan merestrukturisasi data untuk analisis yang lebih efisien.

1.12 Pengantar Normalisasi Basis Data

Normalisasi adalah proses yang digunakan untuk menyusun tabel dalam basis data agar mengurangi duplikasi data, menghindari implikasi modifikasi data, dan menyederhanakan kueri data.

Anomali yang umum terjadi dalam tabel basis data yang tidak dinormalisasi meliputi:

- Insertion Anomaly: Ketika penambahan data baru memerlukan penambahan data tambahan.
- Update Anomaly: Ketika memperbarui satu kolom menyebabkan perlu memperbarui kolom lain di tabel.
- Deletion Anomaly: Ketika penghapusan satu data menyebabkan penghapusan data lain yang diperlukan.

1.13 Tingkatan Normalisasi

1.13.1 First Normal Form(1NF)

Menegakkan atomisitas data dan menghilangkan kelompok data yang berulang.

Contoh: Jika tabel produk M&G menyimpan produk dalam satu sel, ini melanggar aturan atomisitas. Solusinya adalah membuat tabel produk dan tabel klien terpisah, masing-masing dengan kolom ID unik.

1.13.2 Second Normal Form(2NF)

Tabel harus sudah dalam 1NF dan tidak boleh memiliki ketergantungan fungsional atau parsial. Ini hanya terdapat jika primary keynya adalah Composite Primary Key

Contoh: Tabel status pengiriman M&G memiliki kunci primer komposit (order ID dan product ID). Jika ada atribut non-kunci yang hanya bergantung pada satu bagian dari kunci komposit, seperti tanggal pesanan, maka harus dipindahkan ke tabel pesanan.

1.13.3 Third Normal Form (3NF)

menghilangkan duplikasi data yang tidak perlu dan memastikan konsistensi serta integritas data. Untuk sebuah tabel dapat memenuhi 3NF, tabel tersebut harus sudah memenuhi First Normal Form (1NF) dan Second Normal Form (2NF). Selain itu, 3NF juga mengatasi masalah ketergantungan transitif, di mana atribut non-kunci bergantung satu sama lain.

Contoh: Jika kota dan kode pos dalam tabel pesanan M&G saling bergantung, maka harus dipisahkan menjadi dua tabel: satu untuk pesanan dan satu untuk kota, dengan kolom kode pos dan nama kota.

1.14 Pengenalan MySQL Workbench

- MySQL Workbench adalah alat visual yang dikembangkan oleh Oracle untuk pemodelan dan manajemen basis data.
- Alat ini bersifat open source dan dapat digunakan di berbagai sistem operasi.

1.14.1 Fitur Utama MySQL Workbench

- Visual SQL Editor: Memudahkan penulisan pernyataan SQL dengan fitur autocomplete dan highlighting.
- Migrasi Data: Memfasilitasi migrasi data antara versi MySQL yang berbeda dan sistem basis data relasional lainnya.

1.14.2 Membuat Pengguna Baru

- MySQL Connection: Pilih koneksi MySQL untuk mengelola pengguna dan hak akses.
- Login menggunakan pengguna root dan pilih "Users and Privileges" untuk menambah pengguna baru.
- Tentukan nama pengguna, kata sandi, dan hak akses yang sesuai.

1.14.3 Membuat Koneksi MySQL Baru

- Dari layar utama MySQL Workbench, pilih ikon plus untuk membuka formulir koneksi baru.
- Isi formulir dengan nama instance server, username, dan pastikan host-name adalah 127.0.0.1 dengan port 3306.
- Klik "Test Connection" untuk memastikan pengaturan koneksi berhasil.

1.15 Data Management di MySQL Workbench

1.15.1 Membuat Skema Database

Skema adalah struktur yang mendefinisikan cara data disimpan dalam database. Untuk membuat skema baru, pilih opsi "Create Schema" dan masukkan nama skema, misalnya `mg_schema`.

Setelah membuat skema, Anda akan melihat skrip SQL yang dihasilkan, seperti `CREATE SCHEMA 'mg_schema'`. Klik "Apply" untuk menerapkannya.

1.15.2 Membuat Tabel

Tabel adalah struktur yang menyimpan data dalam baris dan kolom. Untuk membuat tabel baru, pilih "Create Table" dan masukkan nama tabel, misalnya `staff`.

Kolom adalah elemen dalam tabel yang menyimpan data. Misalnya, kolom `StaffID` dengan tipe data integer dan ditetapkan sebagai primary key. Kolom lain termasuk `FullName`, `ContactNumber`, `Role`, dan `Email`.

1.15.3 Mengelola Data

Insert Statement digunakan untuk menambahkan data ke tabel. Anda dapat mengisi data langsung di grid tabel dan menggunakan MySQL Workbench untuk menghasilkan pernyataan insert otomatis.

Query adalah proses untuk mengambil data dari database. Anda dapat menggunakan SQL Editor untuk menulis query, seperti `SELECT * FROM staff_view` untuk menampilkan semua data dari tabel `staff_view`.

1.15.4 Membuat View

View adalah tabel virtual yang menyajikan data dari satu atau lebih tabel. Untuk membuat view, gunakan pernyataan SQL `CREATE VIEW` dan tambahkan alias untuk kolom agar lebih mudah dibaca.

1.15.5 Sintaks Penting

- `CREATE SCHEMA 'mg_schema'`: Membuat skema baru.
- `CREATE TABLE staff (...)`: Membuat tabel baru dengan kolom yang ditentukan.
- `INSERT INTO staff (...) VALUES (...)`: Menambahkan data ke tabel.
- `SELECT * FROM staff_view`: Mengambil semua data dari view.

1.16 Database Modeling di MySQL Workbench

1.16.1 Membuat Model Database

- MySQL Workbench: Alat untuk merancang dan mengelola database. Anda dapat membuat model database untuk menyimpan informasi tentang pelanggan dan pesanan.
- Forward Engineering: Proses mengubah model data menjadi skema SQL yang dapat diimplementasikan secara otomatis ke dalam MySQL.

1.16.2 Langkah-langkah Membuat Model

- Membuat Skema: Klik "model's view" dan buat skema baru, misalnya `mangata_gallo`.
- Diagram Data Model: Buat diagram ER (Entity-Relationship) dengan menambahkan tabel.

1.16.3 Menambahkan Tabel dan Kolom

- Menambahkan Tabel: Klik ikon "Add Table" untuk membuat entitas tabel.
- Menambahkan Kolom: Ganti nama kolom default dan atur tipe data serta atribut seperti NOT NULL dan AUTO_INCREMENT.

1.16.4 Mengatur Foreign Key

Foreign Key: Kolom yang menghubungkan tabel satu dengan yang lain. Misalnya, `customer_id_fk` yang merujuk ke customer ID di tabel pelanggan.

1.16.5 Menyimpan dan Mengimplementasikan Model

- Menyimpan Model: Klik "File Save As" untuk menyimpan model dengan nama yang diinginkan.
- Menyinkronkan ke MySQL: Gunakan fitur forward engineer untuk menghubungkan ke server MySQL dan menerapkan skema yang telah dibuat.

1.16.6 Reverse Engineering

Reverse Engineering: Proses membangun diagram ER dari database yang sudah ada.

Langkah-langkah: Pilih opsi reverse engineer dari menu database, pilih skema yang ingin diambil, dan eksekusi untuk mendapatkan diagram ER baru.

1.17 MySQL Workbench untuk Data Modeling dan Data Management

1.17.1 Overview

MySQL Workbench (WB) adalah alat visual terpadu untuk pemodelan basis data dan pengelolaan basis data. WB dikembangkan oleh Oracle, perusahaan yang mengelola MySQL. MySQL Workbench adalah alat gratis, sumber terbuka, dan lintas platform yang dapat dijalankan di Windows, Mac, dan Linux.

MySQL Workbench memungkinkan Anda mempercepat proses desain basis data dengan menggunakan editor SQL visual. Alat ini juga memungkinkan Anda memigrasikan data dari berbagai sistem basis data relasional.

1.17.2 Visual Database Design

MySQL Workbench memudahkan desain dan pemeliharaan basis data. Alat ini memungkinkan insinyur basis data untuk mendokumentasikan persyaratan dalam bentuk diagram ER yang visual. Hal ini memungkinkan Anda untuk berkomunikasi ide desain Anda dengan pemangku kepentingan secara profesional.

Alat desain MySQL WB memfasilitasi pengembangan basis data berbasis model, yang mengotomatiskan proses pengembangan tanpa perlu mengkodekan setiap bagian sistem basis data.

Selain itu, dengan menggunakan MySQL WB, insinyur basis data harus merancang model data yang memenuhi standar yang diharapkan, jika tidak, mereka tidak dapat mengimplementasikan model data tersebut secara langsung di MySQL.

Dengan kata lain, MySQL WB memungkinkan Anda mengembangkan diagram entitas-hubungan yang lengkap dengan tata letak otomatis dan pengaturan model data.

1.17.3 Forward and Reverse Engineer Methods

MySQL Workbench menyediakan fitur untuk membuat model data dalam desain visual. Anda dapat menggunakan metode **Forward Engineer** untuk membuat model data yang relevan di server MySQL Anda. Skema SQL akan dihasilkan secara otomatis untuk Anda. Anda dapat mengedit kode jika diperlukan, atau menjalankannya dengan beberapa klik mouse.

MySQL Workbench juga menawarkan metode **Reverse Engineer**. Anda dapat menggunakan metode ini untuk membuat atau mengimpor berkas basis data MySQL, lalu menghasilkan model data yang relevan dari skrip SQL. Anda dapat memodifikasi model jika diperlukan, dan kemudian menggunakan metode Forward Engineer untuk membuat sistem basis data baru di MySQL.

1.17.4 Database Management

Pengelolaan database umumnya melibatkan pemeliharaan berbagai versi skema database Anda. Untuk membantu Anda dalam pengelolaan database, MySQL WB dapat digunakan untuk melakukan fungsi Sinkronisasi dan Perbandingan Skema. Fitur-fitur ini memungkinkan Anda untuk membandingkan dua database atau sebuah database dengan model data, sehingga Anda dapat secara visual mendeteksi perbedaan di antara keduanya. MySQL WB juga memungkinkan Anda untuk menyinkronkan model data dengan database yang aktif dan sebaliknya.

1.17.5 Database Documentation

Sebagai seorang insinyur basis data, Anda perlu mendokumentasikan desain basis data Anda. Hal ini dapat memakan waktu yang cukup lama. MySQL

Workbench menyediakan alat dokumentasi bernama DBDoc untuk mendokumentasikan semua detail desain basis data Anda. Anda dapat menggunakan alat ini untuk menghasilkan dokumentasi model basis data Anda dalam format HTML atau teks biasa.

1.17.6 Visual SQL Editor

MySQL WB visual SQL editor digunakan untuk menulis, menjalankan, dan mendebug pernyataan SQL. Alat ini juga memudahkan penyelesaian kode SQL dan menyediakan daftar kata kunci dan objek SQL yang sensitif terhadap konteks.

Selain itu, editor ini dilengkapi dengan pemformat kode SQL yang secara otomatis memformat kode SQL agar lebih mudah dibaca dan diedit. Fitur berguna lainnya meliputi:

- Penyorotan sintaksis SQL,
- Pembangkitan kode SQL,
- Kemampuan untuk menggunakan kembali potongan kode SQL favorit Anda,
- Riwayat eksekusi semua kueri SQL yang dijalankan,

Dan kemampuan untuk dengan cepat membuat tabel, indeks, tampilan, prosedur tersimpan, pemicu, dan fungsi.

1.17.7 Visual Database Administration

Dengan MySQL WB, Anda memiliki kendali administratif penuh atas semua aspek server MySQL Anda, termasuk:

- Akun pengguna,
- Peran,
- Hak akses,
- Mulai/henti server,
- Log,
- Dan konfigurasi server.

1.17.8 Data Management

MySQL WB menyediakan fitur-fitur berguna untuk mengelola data dalam basis data MySQL, termasuk kemampuan untuk mengimpor dan mengekspor berkas mysqldump, serta mengekspor hasil kueri sebagai berkas CSV, XML, dan HTML.

WB Visual Data Editor juga memungkinkan Anda untuk melihat dan mengedit hasil kueri dalam tabel grid.

Anda juga dapat melihat beberapa hasil kueri dalam jendela data visual yang sama. Dan Anda dapat melakukan pencarian data dan pencarian pola di seluruh tabel dan skema.

1.17.9 Data Migration

Di MySQL WB, Anda dapat menggunakan Database Migration Wizard untuk melakukan migrasi data antara versi yang berbeda dari server MySQL.

Selain itu, Anda juga dapat melakukan migrasi data dengan sistem manajemen basis data relasional lainnya seperti Microsoft SQL Server, Sybase ASE, Sybase SQL Anywhere, PostgreSQL, dan SQLite.

2 Data Warehousing

2.1 Apa itu Data Warehouse?

Data Warehouse adalah repositori data terpusat yang mengumpulkan, menyimpan, dan memproses data dari berbagai sumber. Ini memisahkan beban kerja analisis data dari beban kerja transaksi standar dari sistem manajemen basis data biasa.

Pengguna dapat melakukan query pada data ini untuk melakukan analisis data. Tipe basis data ini dikenal sebagai Online **Analytical Processing (OLAP)**.

2.2 Karakteristik Utama Data Warehouse

2.2.1 Subject-Oriented

Data warehouse dibangun dengan fokus pada satu atau lebih area subjek. Misalnya, global superstore dapat membangun data warehouse yang fokus pada penjualan untuk menemukan informasi terkait proses penjualan mereka.

2.2.2 Integrated

Data warehouse mengintegrasikan data dari berbagai sumber dalam format yang konsisten. Ini juga menyelesaikan masalah seperti konflik penamaan dan tipe data. Contohnya, data dari pembelian online, interaksi website, dan media sosial diintegrasikan.

2.2.3 Non-Volatile

Data yang dimuat ke dalam data warehouse tidak boleh dihapus. Tujuan dari data warehouse adalah untuk menganalisis data sebagaimana adanya, sehingga semakin banyak data yang ada, semakin baik hasil analisisnya.

2.2.4 time-Variant

Data warehouse mengumpulkan data selama periode yang panjang untuk mengukur perubahan data dari waktu ke waktu. Ini membantu pengguna menemukan tren, pola, dan hubungan antara elemen data.

2.3 Jenis Data dalam Data Warehouse

2.3.1 Structured Data

Data yang disajikan dalam format terstruktur dalam model data yang terdefinisi dengan baik, seperti model basis data relasional.

2.3.2 Semi-Structured Data

Data yang hanya sebagian terstruktur dan memerlukan lebih banyak usaha untuk analisis. Contohnya adalah email yang memiliki data terstruktur seperti pengirim dan subjek, tetapi isi emailnya tidak terstruktur.

2.3.3 Unstructured Data

Data yang tidak mengikuti model data yang terdefinisi. Ini bisa mencakup teks, video, atau audio. Menganalisis data tidak terstruktur memerlukan mekanisme analitik data yang lebih canggih seperti machine learning dan data mining.

2.4 Komponen Arsitektur Data Warehouse




Figure 5:

Sumber Data:

- Sumber data eksternal seperti Global Super Store, survei online, atau data media sosial.
- Sumber data internal dari database perusahaan mengenai pelanggan dan produk, serta data operasional dari aktivitas bisnis sehari-hari.

Data Staging:

- Area staging data mencakup proses ETL (Extract, Transform, Load) yang digunakan untuk mengekstrak data dari sumber, mengubahnya ke format yang konsisten, dan memuatnya ke dalam data warehouse.

2.5 Penyimpanan dan Metadata

Data Storage merupakan repositori database pusat yang menyimpan data dalam format relasional. Ini juga mencakup metadata yang berisi informasi tentang data, seperti asal data dan atribut tabel.

Metadata adalah "daftar isi" untuk data dalam data warehouse, membantu insinyur database mengelola dan melacak perubahan dalam sistem sumber mereka.

2.6 Data Marts dan Analisis Data

Data Marts adalah basis data yang berfokus pada subjek tertentu untuk memenuhi kebutuhan kelompok pengguna tertentu, seperti departemen dalam organisasi.

Data Analytics: Proses analisis data menggunakan teknik seperti data mining untuk menghasilkan laporan yang memberikan informasi penting tentang penjualan, keuntungan, dan aspek lainnya dari bisnis.

2.7 Praktik Terbaik terkait Data Warehousing

- Pisahkan operasi analitis dan transaksional.
- Gunakan solusi yang dapat diskalakan untuk memproses data yang semakin besar.
- Bangun arsitektur yang fleksibel dan mudah dipahami, serta dokumentasikan pengembangan data warehouse.

2.8 Pendalaman Data Warehouse ETL Process

2.8.1 Overview

ETL adalah singkatan dari "Extract, Transform, and Load". Ini merupakan bagian penting dari fase penyiapan data dalam arsitektur data warehouse. ETL menggambarkan serangkaian proses yang mengekstrak data dari sistem sumber yang berbeda, mengubah data menjadi format yang sesuai, dan memuatnya ke dalam repositori data warehouse untuk analisis data.

Secara umum, data warehousing melibatkan proses ETL yang kompleks dan memerlukan keterlibatan aktif dari pemangku kepentingan, termasuk insinyur data, analis data, analis bisnis, penguji, dan manajer.

Sebagai insinyur database, Anda harus mengevaluasi dengan cermat setiap perubahan yang berdampak pada bisnis dalam desain proses ETL di data warehouse. Anda harus memastikan pemisahan yang lengkap antara operasi analitik dan operasi transaksional sehari-hari. Anda juga memerlukan solusi yang skalabel untuk memproses jumlah data yang sangat besar.

2.8.2 Bagaimana ETL Bekerja

Proses ETL tiga langkah mewakili alur kerja yang memindahkan data dari berbagai sumbernya dan mengintegrasikannya ke dalam data warehouse. Ada tiga langkah dalam proses ini:

- Ekstraksi data.

- Transformasi.
- Dan pemuatan.

2.8.3 Step 1: Data Extraction

Langkah ini dalam proses melibatkan pengambilan data dari berbagai sumber ke area penyimpanan sementara. Misalnya, Global Super Store mungkin menggunakan sistem manajemen basis data dan file yang berbeda untuk mengelola data mereka di departemen logistik, operasional, penjualan, dan pemasaran. Hal ini dapat mencakup MySQL, Oracle, PostgreSQL, lembar Excel, dan file teks biasa, seperti yang ditunjukkan dalam diagram berikut.




Figure 6:

Global Super Store mengekstrak data dari masing-masing sumber ini di area persiapan. Saat merancang proses ini, penting bagi Anda untuk:

- Hanya mengekstrak data yang relevan untuk menghindari kelebihan data.
- Menyertakan data yang valid dan menghapus semua duplikasi untuk mendapatkan hasil yang lebih akurat.
- Mengecualikan data spam dan data yang rusak, karena hal ini akan menghemat banyak waktu selama proses pembersihan dan persiapan data.
- Memvalidasi data dengan data asli di sumber untuk memastikan data dapat digunakan dengan cara yang sama di data warehouse.

2.8.4 Step 2: Transformation

Proses ini memerlukan konversi data dari satu format ke format lain, atau dari satu struktur ke struktur lain sesuai dengan model data yang telah ditetapkan

di data warehouse. Langkah ini sangat penting untuk mengintegrasikan data ke dalam repositori data warehouse.

Data yang sudah terintegrasi dalam basis data relasional mungkin tidak memerlukan transformasi. Data tersebut dapat diimpor langsung ke repositori data warehouse tanpa perubahan. Namun, Anda mungkin perlu membersihkan dan mempersiapkan data sebelum menggunakannya untuk analisis data.

Misalnya, jika nilai nama depan dan nama belakang pelanggan disimpan terpisah dalam dua kolom yang berbeda, maka keduanya dapat digabungkan ke dalam kolom 'nama lengkap' sebelum dimuat ke repositori data warehouse. Atau jika data mencakup biaya pembelian dan penjualan, maka Anda dapat membuat kolom baru yang dihitung untuk keuntungan data.

Transformasi data menjadi lebih penting ketika Anda bekerja dengan data mentah (seperti jenis data atomik yang tidak dapat diolah menjadi informasi berguna oleh komputer secara mandiri). Contoh data mentah yang baik meliputi log komputer, cookie navigasi pengguna, dan riwayat pencarian. Jenis data ini dapat ditemukan dalam file teks biasa atau file nilai yang dipisahkan koma (CSV).

Dalam data warehouse, Anda harus menyertakan data terstruktur untuk analisis data. Untuk melakukannya, Anda harus mengorganisir data yang telah diubah dalam tabel, mendefinisikan data dengan tipe data spesifik, dan menetapkan batasan dalam tabel dan kolom. Hal ini menciptakan catatan data terkait yang dapat diakses, diinterogasi, dan dianalisis untuk menyajikan informasi yang berguna.

Tugas utama dalam proses transformasi meliputi pemformatan, pembersihan, persiapan, pengorganisasian, dan integrasi data, seperti yang ditunjukkan dalam diagram berikut.




Figure 7:

Penting juga untuk memastikan integritas dan konsistensi data pada fase

Transformasi. Misalnya, nama pelanggan mungkin ditulis dengan cara yang berbeda di berbagai sumber data, seperti John atau Jon. Atau nomor telepon dapat dicatat dengan cara yang berbeda (misalnya, dengan atau tanpa kode negara). Tanggal dan waktu juga dapat dikumpulkan dalam format yang berbeda.

2.8.5 Step 3: Loading

Proses ini merupakan langkah terakhir dalam ETL. Pada langkah ini, sejumlah besar data dimuat ke dalam repositori data warehouse. Oleh karena itu, penting untuk menerapkan mekanisme pemulihan jika terjadi kegagalan pemuatan data. Hal ini berarti Anda dapat melanjutkan proses pemuatan dari titik kegagalan tanpa kehilangan data dan sambil tetap menjaga integritas data.

Dalam konteks ini, Anda dapat melakukan tiga jenis pemuatan data:

- Pemuatan awal: Memuat data yang diekstraksi ke repositori data warehouse.
- Pemuatan incremental: Memuat data baru dari sumber data ke repositori saat ini.
- Pemuatan refresh penuh: Menghapus isi database di repositori data warehouse secara sebagian atau seluruhnya dan memuatnya kembali dengan data baru yang segar.




Figure 8:

2.8.6 ETL Tools

Ada beberapa alat yang tersedia yang dapat Anda gunakan untuk melaksanakan proses ETL ini. Alat-alat ini mengotomatisasi proses ekstraksi, transformasi,

dan pemuatan data ke tingkat yang lebih canggih. Beberapa contoh alat-alat tersebut antara lain:

- Oracle: Database terkemuka di industri yang menawarkan berbagai pilihan solusi data warehouse.
- Amazon RedShift: Alat data warehouse yang sederhana dan hemat biaya yang dapat digunakan untuk menganalisis berbagai jenis data.
- MarkLogic: Solusi data warehouse yang memudahkan dan mempercepat integrasi data dibandingkan alat lain. Ia dapat mengakses berbagai jenis data seperti data mesin pencari, file teks, dan RDF.

2.9 Tujuan dan Tantangan ETL

Tujuan:

- ETL bertujuan untuk menggabungkan berbagai sumber data atau mengabstraksi sumber data besar agar lebih mudah diakses oleh konsumen data.
- Proses ini memungkinkan penyimpanan data mentah sebagai cadangan di warehouse, sambil menyediakan data yang telah diproses untuk penggunaan saat dibutuhkan.

Tantangan:

- Mengelola volume data yang besar dan beragam bisa menjadi tantangan. Memastikan pipeline selalu diperbarui dan data tersedia saat dibutuhkan adalah kunci.
- Perubahan pada database dapat memicu kebutuhan untuk memperbarui pipeline ETL, yang memerlukan pemahaman yang kuat tentang kebutuhan dan tujuan pipeline tersebut.

Pemangku kepentingan harus memiliki pemahaman yang baik tentang pipeline ETL dan bertanggung jawab untuk melakukan perubahan yang diperlukan saat ada pembaruan.

ETL pipelines adalah komponen fundamental dalam dunia big data, cloud computing, dan metaverse, membantu dalam pengelolaan dan akses data yang efisien.

2.10 ETL Testing

2.10.1 Overview

Data warehouse menyediakan repositori data terpusat yang mendukung analisis data canggih dan pelaporan. ETL merujuk pada proses Ekstrak, Transformasi, dan Pemuatan yang diperlukan untuk memindahkan data dari berbagai sumber data ke dalam data warehouse.

Untuk menyelesaikan proses ETL, Anda perlu:

- Mengekstrak data yang relevan dan valid.
- Mengubah data yang diekstrak menjadi format dan struktur yang sesuai.
- Dan memuat data yang telah diubah dari berbagai sumber data ke dalam repositori data warehouse.

Namun, bagaimana Anda dapat memastikan bahwa data yang dimuat benar, valid, andal, dan konsisten?

2.10.2 ETL Testing

Tujuan utama pengujian ETL adalah untuk memastikan akurasi, keandalan, validitas, dan konsistensi data yang dimuat. Pengujian ETL memeriksa apakah ada masalah dalam proses ETL yang menghalangi pembentukan data berkualitas baik. Hal ini dapat dilakukan dengan melaksanakan tindakan berikut:

- Pemetaan data secara tepat.
- Memvalidasi data.
- Memeriksa duplikat data.
- Memvalidasi tanggal.
- Dan memverifikasi kelengkapan dan keakuratan data.

2.10.3 ETL Testing in Practice

Global Super Store memiliki banyak departemen yang berbeda, masing-masing mengelola data pelanggan dengan cara yang berbeda di server yang berbeda menggunakan identifikasi unik yang berbeda. Misalnya, departemen penjualan menggunakan nomor telepon pelanggan sebagai identifikasi unik, sementara departemen pemasaran menggunakan identifikasi pelanggan yang dihasilkan secara otomatis.

Selain itu, beberapa data diwakili dengan cara yang berbeda. Misalnya, nama lengkap pelanggan dinyatakan sebagai satu kolom di departemen penjualan. Namun, di departemen pemasaran, nama lengkap pelanggan dinyatakan dalam dua kolom (sebagai nama depan dan nama belakang). Tanggal di departemen penjualan diformat sebagai `yyyy-m-d` (misalnya `2020-9-5`). Namun, di departemen pemasaran, tanggal diformat sebagai `yy\m\d` (atau `20\9\5`).

Hal ini menimbulkan beberapa masalah bagi Global Super Store. Masalah utama yang tidak dapat mereka selidiki adalah siapa pelanggan yang melakukan pemesanan setelah kampanye pemasaran terbaru mereka, karena ID pelanggan disimpan dalam format yang berbeda di berbagai departemen. Solusi untuk masalah ini adalah membuat model database baru di data warehouse. Mereka kemudian dapat mengekstrak data yang relevan, mentransformasikannya, dan memuatnya dari database penjualan dan pemasaran.

Model baru ini dapat mencakup:

- Tabel Pesanan dengan ID pesanan dan tanggal pesanan.
- Tabel Pemasaran dengan ID pemasaran dan tanggal pemasaran.
- Dan tabel pelanggan dengan nama lengkap setiap pelanggan, identifikasi unik awal dari kedua departemen, dan kunci unik baru yang memungkinkan identifikasi pelanggan dari kedua departemen.

Model baru ini memungkinkan untuk menghubungkan riwayat pembelian pelanggan dengan kampanye pemasaran, dan kemudian melakukan analisis data yang relevan.

2.10.4 Performing ETL Testing

Untuk memastikan bahwa data telah dimuat dengan benar, pengujian ETL harus dilakukan menggunakan metode-metode berikut.

- Dokumen pemetaan data
Buat dokumen pemetaan data untuk mentransformasi data dari sumber data kedua departemen ke repositori tujuan di data warehouse. Dokumen ini harus direview, diverifikasi, dan divalidasi oleh insinyur database dan analis data untuk memastikan pemetaan data yang benar.
- Validasi data
Lakukan validasi data dengan membandingkan struktur data, tipe data, format data, dan batasan dalam tabel sumber dan tujuan yang terkait dengan dokumen pemetaan yang sesuai. Anda juga harus melakukan validasi data untuk memverifikasi nilai tanggal saat membuat catatan data baru, karena hal ini memungkinkan sistem data warehouse untuk mengekstrak data baru dari sumber data dan memperbarui basis data repositori yang relevan jika terjadi perubahan data.
- Kelengkapan data
Pastikan kelengkapan data dengan memverifikasi bahwa semua data yang diharapkan telah dimuat ke dalam tabel tujuan, termasuk jumlah catatan dan catatan yang ditolak. Anda juga perlu memeriksa batasan yang telah diterapkan dan memastikan bahwa semua nilai unik telah diisi sesuai persyaratan.
- Kebenaran data
Lakukan verifikasi kebenaran data untuk menyelesaikan konflik penamaan data, pastikan semua data yang salah eja telah diperbaiki, dan pastikan nilai data yang tidak terduga (artinya, nilai yang di luar rentang) telah diperbaiki atau dihapus.
- Kualitas data
Pastikan kualitas data yang baik dengan memeriksa nama dan format angka, presisi, serta nilai null di mana batasan NOT NULL telah ditentukan.

- Data unik

Lakukan pemeriksaan duplikat untuk memastikan semua tabel memiliki catatan data yang unik dan semua catatan data duplikat telah dihapus.

2.11 Konsep Dasar Dimensional Data Modeling

- **Dimensi:** Elemen yang berbeda dari data yang memberikan konteks untuk ukuran. Contoh: waktu dan lokasi dalam database Global Superstore.
- **Fakta:** Data yang dapat diukur dan dihitung dalam database. Contoh: jumlah produk yang terjual dan keuntungan yang diperoleh.

2.12 Struktur Dimensional Data Model

- Tabel Dimensi: Menyimpan elemen data dimensi dan dapat disusun dalam hierarki untuk analisis data yang lebih mendalam.
- Tabel Fakta: Menyimpan ukuran data. Contoh: tabel fakta penjualan yang terhubung dengan tabel dimensi seperti pemasok, pelanggan, produk, waktu, dan lokasi.

2.13 Jenis Ukuran dalam Tabel Fakta

- Stored Measures: Ukuran yang disimpan dalam data warehouse, seperti data penjualan dan harga produk.
- Calculated Measures: Ukuran yang dihitung dari ukuran lain, misalnya, keuntungan dihitung dengan mengurangi biaya produk dari harga jual.

2.14 Skema dalam Dimensional Data Modeling

- Star Schema: Model sederhana yang terdiri dari tabel fakta di tengah yang terhubung dengan satu atau lebih tabel dimensi. Contoh: tabel fakta penjualan terhubung dengan tabel dimensi pemasok, pelanggan, produk, waktu, dan lokasi.
- Snowflake Schema: Skema yang lebih kompleks di mana tabel dimensi dinormalisasi untuk menghilangkan redundansi data. Contoh: tabel produk dinormalisasi menjadi tabel produk, subkategori, dan kategori.

2.15 Praktik Terbaik dalam Mendesain Data Model Warehouse

Tentukan aktivitas bisnis yang ingin dianalisis dan dimensi yang memberikan konteks yang paling berarti.

Organisasi data harus mudah dipahami, diakses, dan di-query.

3 Advanced Data Analytics

4 Model and Analyze Data